



ЦЕНТР
ДОПОЛНИТЕЛЬНОГО
ОБРАЗОВАНИЯ
МГТУ им. Н.Э. Баумана

Прогнозирование конечных свойств композиционных материалов

Мельниченко Мария Николаевна



ЦЕНТР
ДОПОЛНИТЕЛЬНОГО
ОБРАЗОВАНИЯ
МГТУ им. Н.Э. Баумана

Актуальность и цель работы

1

Проблема: создание новых композитов требует дорогих физических испытаний

2

Идея: заменить часть испытаний прогнозными ML-моделями

3

Значимость: ускорение разработки и пополнение базы цифровых двойников

4

Цель: прогнозировать свойства композитов и рекомендовать соотношение матрица-наполнитель

5

Данные: производственный кейс Центра НТИ «Цифровое материаловедение» МГТУ им. Н.Э. Баумана



Задачи работы

1

Обучить модель прогнозирования модуля упругости при растяжении (ГПа)

2

Обучить модель прогнозирования прочности при растяжении (МПа)

3

Разработать нейронную сеть для рекомендации соотношения матрица-наполнитель

4


Создать веб-приложение для практического использования моделей

Типы задач:

- Задачи 1-2 – регрессия (непрерывные свойства);
- Задача 3 – обратная задача (по свойствам предсказать рецептуру);
- Задача 4 – интеграция модели в приложение



Пайплайн работы





ЦЕНТР
ДОПОЛНИТЕЛЬНОГО
ОБРАЗОВАНИЯ
МГТУ им. Н.Э. Баумана

Данные для исследования


Два датасета от Центра НТИ «Цифровое материаловедение» МГТУ им. Н.Э. Баумана

1. X_br.xlsx – параметры базальтопластика (1023 строки, 10 столбцов);
2. X_nip.xlsx – параметры нашивок углепластика (1040 строк, 3 столбца).
3. Объединение **INNER JOIN** по индексу:
итоговый размер объединённого датасета – 1023 строки, 13 столбцов




Разведочный анализ данных

1. Пропуски и дубликаты отсутствуют
2. Построены графики






Разведочный анализ данных






Разведочный анализ данных





Разведочный анализ данных


Матрица корреляции признаков





Предобработка данных


1. Удаление выбросов - IQR-метод (1023 строки -> 921 строка)
1. Нормализация – MinMaxScaler
2. Разделение на train/test (70/30)





Модели прогнозирования свойств

- Обучено 5 моделей для каждой целевой переменной
- Поиск гиперпараметров — GridSearchCV, 10-кратная кросс-валидация
- Разделение данных — 70% обучение / 30% тест
- Метрики оценки — MAE, RMSE, R^2



Список моделей:

- Множественная линейная регрессия
- Случайный лес (Random Forest)
- Градиентный бустинг (XGBoost)
- Метод опорных векторов (SVR)
- К-ближайших соседей (KNN)



Оценка моделей прогнозирования

Модуль упругости при растяжении (ГПа)

Model	MAE	RMSE	R2
Linear Regression	2.455	3.013	-0.0001
Random Forest	2.457	3.026	-0.0088
XGBoost	2.465	3.019	-0.0042
SVR	2.445	3.005	0.0049
KNN	2.566	3.140	-0.0862

Прочность при растяжении (МПа)

Model	MAE	RMSE	R2
Linear Regression	384.030	474.086	0.0012
Random Forest	384.623	475.115	-0.0031
XGBoost	383.043	475.344	-0.0041
SVR	383.595	474.458	-0.0003
KNN	401.683	497.752	-0.1010

Выводы:

1. Все модели дают $R^2 \approx 0$
2. Лучшие: SVR для модуля ($R^2 = 0.005$), линейная регрессия для прочности ($R^2 = 0.001$)
3. Модели не превосходят baseline



Нейронная сеть

Тип: полносвязная нейронная сеть (MLP)

Архитектура: 12 → 64 → 32 → 1



Регуляризация: Dropout 0.2 после каждого скрытого слоя

Обучение: 200 эпох, batch_size = 32, validation_split = 0.2

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 64)	832
dropout (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 32)	2,080
dropout_1 (Dropout)	(None, 32)	0
dense_2 (Dense)	(None, 1)	33

Total params: 2,945 (11.50 KB)

Trainable params: 2,945 (11.50 KB)





Результаты нейронной сети

Нейронная сеть

MAE: 0.1505
RMSE: 0.1867
 R^2 : -0.0105

Сравнение с baseline

Baseline MAE: 0.1496
MAE модели: 0.1505
 R^2 baseline: 0.0000 (по определению)

Модель не лучше baseline

R^2 отрицательный – модель хуже среднего

Причина: слабые связи признаков с целевой переменной

Модель «схлопнулась» в константу 0.4857



Разработка веб-приложения

Файл	Назначение
main.py	Код FastAPI-приложения
nn_matrix_filler.keras	Обученная нейронная сеть
scaler_minmax.pkl	Сохранённый нормализатор
feature_order.pkl	Порядок входных признаков
requirements.txt	Список зависимостей Python

Структура проекта: код, модель, нормализатор, порядок признаков, зависимости

Server response	
Code	Details
200	Response body <pre>{ "matrix_filler_ratio": 0.48569855093955994 }</pre>

Результат успешного тестирования API: код 200, прогноз 0.4857

Прогноз соотношения матрица-наполнитель

Плотность, кг/м³:

Модуль упругости связующего, ГПа:

Количество отвердителя, м.-%:

Содержание эпоксидных групп, %:

Температура всплышки, °C:

Поверхностная плотность, г/м²:

Модуль упругости при растяжении, ГПа:

Прочность при растяжении, МПа:

Потребление смолы, г/м²:

Угол нашивки, град:

Шаг нашивки:

Плотность нашивки:

Рассчитать

Рекомендованное соотношение:
0.4857

Веб-интерфейс приложения



ЦЕНТР
ДОПОЛНИТЕЛЬНОГО
ОБРАЗОВАНИЯ
МГТУ им. Н.Э. Баумана

Репозиторий

Ссылка на GitHub: <https://github.com/melnichenko-ds/Composite-Materials>



Заключение

Блок 1. Выполненные задачи

- ☒ Обучить модели прогнозирования модуля упругости и прочности
- ☒ Разработать нейронную сеть для рекомендации соотношения
- ☒ Создать веб-приложение
- ☒ Разместить код в репозитории

Блок 2. Ключевые результаты

Модели для свойств: не превзошли базовую модель ($R^2 \approx 0$)

Нейросеть: $R^2 = -0.01$ (не превзошла базовую модель)

Приложение: работает корректно (FastAPI + веб-интерфейс)

Блок 3. Ценность работы

Продemonстрирован полный цикл Data Science: EDA → модели → деплой

Выявлены ограничения исходных данных: слабые корреляции

Создана основа для дальнейших исследований: код, приложение, репозиторий



ЦЕНТР
ДОПОЛНИТЕЛЬНОГО
ОБРАЗОВАНИЯ
МГТУ им. Н.Э. Баумана



do.bmstu.ru