

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по курсу
«Наука о данных: профессиональный уровень (Data Science PRO)»

Слушатель

Мельниченко Мария Николаевна

Москва, 2026

Содержание

Введение	3
Аналитическая часть	4
1.1 Постановка задачи.....	4
1.2 Описание используемых методов	8
1.3 Разведочный анализ данных	10
Практическая часть	15
2.1 Предобработка данных	15
2.2 Разработка и обучение модели	18
2.3 Тестирование модели	20
2.4 Нейронная сеть	22
2.5 Разработка приложения.....	26
2.6. Удалённый репозиторий.....	29
Заключение.....	30
Библиографический список.....	32

Введение

Современное материаловедение сталкивается с фундаментальной проблемой: создание новых композиционных материалов требует значительных временных и финансовых затрат на проведение физических экспериментов. Композиты обладают уникальными свойствами, которые не наблюдаются у компонентов по отдельности, однако прогнозирование конечных характеристик композита на основе свойств его составляющих является нетривиальной задачей. Традиционный метод проб и ошибок, предполагающий изготовление и испытание множества образцов, становится экономически неэффективным и ресурсозатратным.

Целью данной выпускной квалификационной работой является прогнозирование свойств композиционных материалов (модуля упругости при растяжении и прочность при растяжении). Для достижения данной цели мы разработаем модели машинного обучения для прогнозирования вышеупомянутых свойств.

Работа включает в себя полный цикл анализа данных: от разведочного анализа до обучения моделей машинного обучения, разработки нейронной сети и создания приложения для практического использования разработанных моделей. Для выполнения поставленных задач Центром НТИ «Цифровое материаловедение: новые материалы и вещества» были предоставлены реальные производственные данные.

Актуальность работы обусловлена как практической значимостью для материаловедческой отрасли, так и методической ценностью, ведь база данных материалов будет пополнена возможными новыми характеристиками материалов и цифровыми двойниками новых композитов.

Аналитическая часть

1.1 Постановка задачи

Для прогнозирования конечных свойств новых композиционных материалов в рамках данной работы были определены следующие задачи:

- 1) обучить алгоритм машинного обучения для прогнозирования модуля упругости при растяжении (ГПа);
- 2) обучить алгоритм машинного обучения для прогнозирования прочности при растяжении (МПа);
- 3) разработать нейронную сеть, которая будет рекомендовать оптимальное соотношение матрица-наполнитель;
- 4) создать приложение, позволяющее пользователю вводить определённые параметры и получать прогноз соотношения матрица-наполнитель, рекомендованное нейронной сетью.

Для решения поставленных задач используются два файла, предоставленных Центром НТИ «Цифровое материаловедение: новые материалы и вещества» МГТУ им. Н.Э. Баумана.

Первый датасет (X_br.xlsx) содержит данные о параметрах базальтопластика. Состоит из 1024 строки и 10 столбцов.

Второй датасет (X_nip.xlsx) содержит данные о нашивках углепластика. Состоит из 1040 строк и 3 столбца.

При загрузке данных первый столбец «Unnamed: 0», содержащий порядковые номера записей, был исключён из состава признаков путём назначения его в качестве индекса DataFrame. Таким образом, размерность каждого датасета сократилась на один столбец без потери информативности.

Два датасета были объединены по индексу (тип объединения – INNER). В результате итоговая выборка содержит 1023 строки и 13 столбцов в соответствии с рисунком 1. 17 строк из датасета X_nip.xlsx были удалены по причине их отсутствия в первом датасете (INNER оставил то, что есть в двух датасетах).

Объединение датасетов:

```
[7]: df = pd.merge(df_bp, df_nup, left_index=True, right_index=True, how='inner')
print(f"Размер объединённого датасета: {df.shape[0]} строки, {df.shape[1]} столбцов")
```

Размер объединённого датасета: 1023 строки, 13 столбцов

```
[12]: #просмотр первых пяти строк объединённого датасета
df.head().T #используем атрибут T для удобного просмотра всех столбцов
```

[12]:	0	1	2	3	4
Соотношение матрица-наполнитель	1.857143	1.857143	1.857143	1.857143	2.771331
Плотность, кг/м3	2030.000000	2030.000000	2030.000000	2030.000000	2030.000000
модуль упругости, ГПа	738.736842	738.736842	738.736842	738.736842	753.000000
Количество отвердителя, м.%	30.000000	50.000000	49.900000	129.000000	111.860000
Содержание эпоксидных групп,%_2	22.267857	23.750000	33.000000	21.250000	22.267857
Температура вспышки, C_2	100.000000	284.615385	284.615385	300.000000	284.615385
Поверхностная плотность, г/м2	210.000000	210.000000	210.000000	210.000000	210.000000
Модуль упругости при растяжении, ГПа	70.000000	70.000000	70.000000	70.000000	70.000000
Прочность при растяжении, МПа	3000.000000	3000.000000	3000.000000	3000.000000	3000.000000
Потребление смолы, г/м2	220.000000	220.000000	220.000000	220.000000	220.000000
Угол нашивки, град	0.000000	0.000000	0.000000	0.000000	0.000000
Шаг нашивки	4.000000	4.000000	4.000000	5.000000	5.000000
Плотность нашивки	57.000000	60.000000	70.000000	47.000000	57.000000

Рисунок 1 – Объединение датасетов, объём входных данных

В рамках задач прогнозирования механических свойств (задача 1 и 2) используются 11 входных признаков и 2 выходных переменные (модуль упругости при растяжении и прочность при растяжении). Для рекомендации соотношения матрица-наполнитель (задача 3) с помощью нейронной сети входными признаками являются все 12 столбцов, кроме выходной переменной - соотношения матрица-наполнитель.

В соответствии с рисунком 2, была проанализирована информация о датафрейме и самое главное то, что все столбцы представлены числовыми данными: 12 столбцов имеют тип float64, 1 столбец (Угол нашивки, град) – тип int64. Проверка на пропуски и дубликаты показала, что их нет.

```
[19]: df.info() #анализ информации о датафрейме

<class 'pandas.DataFrame'>
RangeIndex: 1023 entries, 0 to 1022
Data columns (total 13 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   Соотношение матрица-наполнитель          1023 non-null   float64
1   Плотность, кг/м3                          1023 non-null   float64
2   модуль упругости, ГПа                     1023 non-null   float64
3   Количество отвердителя, м.%               1023 non-null   float64
4   Содержание эпоксидных групп,%_2          1023 non-null   float64
5   Температура вспышки, C_2                  1023 non-null   float64
6   Поверхностная плотность, г/м2             1023 non-null   float64
7   Модуль упругости при растяжении, ГПа      1023 non-null   float64
8   Прочность при растяжении, МПа             1023 non-null   float64
9   Потребление смолы, г/м2                   1023 non-null   float64
10  Угол нашивки, град                         1023 non-null   int64
11  Шаг нашивки                               1023 non-null   float64
12  Плотность нашивки                         1023 non-null   float64
dtypes: float64(12), int64(1)
memory usage: 104.0 KB

[20]: print(df.isnull().sum()) #проверка на пропуски

Соотношение матрица-наполнитель      0
Плотность, кг/м3                      0
модуль упругости, ГПа                 0
Количество отвердителя, м.%           0
Содержание эпоксидных групп,%_2       0
Температура вспышки, C_2              0
Поверхностная плотность, г/м2         0
Модуль упругости при растяжении, ГПа  0
Прочность при растяжении, МПа         0
Потребление смолы, г/м2               0
Угол нашивки, град                    0
Шаг нашивки                           0
Плотность нашивки                     0
dtype: int64

[21]: print(df.duplicated().sum()) #проверка на дубликаты

0
```

Рисунок 2 – Анализ типов данных, проверка на пропуски и дубликаты

В процессе анализа также была проведена проверка количества уникальных значений в каждом столбце. В столбце «Угол нашивки, град» обнаружено только два уникальных значения: 0 и 90. Поскольку данный признак является бинарным, для единообразия представления он был преобразован к виду {0, 1} путём замены значения 90 на 1 в соответствии с рисунком 3.

```
[48]: print(df.nunique()) #проверка количества уникальных значений в каждом столбце

Соотношение матрица-наполнитель      1014
Плотность, кг/м3                       1013
модуль упругости, ГПа                  1020
Количество отвердителя, м.%            1005
Содержание эпоксидных групп,%_2       1004
Температура вспышки, C_2               1003
Поверхностная плотность, г/м2         1004
Модуль упругости при растяжении, ГПа   1004
Прочность при растяжении, МПа          1004
Потребление смолы, г/м2                1003
Угол нашивки, град                     2
Шаг нашивки                            989
Плотность нашивки                       988
dtype: int64

[49]: #в столбце "Угол нашивки" только два уникальных значений
df['Угол нашивки, град'].value_counts()

[49]: Угол нашивки, град
0      520
1      503
Name: count, dtype: int64

[50]: df['Угол нашивки, град'] = df['Угол нашивки, град'].replace({90: 1, 0: 0}) #приведение бинарного признака к виду {0, 1} для единообразия

[52]: df['Угол нашивки, град'] #просмотр успешного изменения значений

[52]: 0      0
1      0
2      0
3      0
4      0
..
1018   1
1019   1
1020   1
1021   1
1022   1
Name: Угол нашивки, град, Length: 1023, dtype: int64
```

Рисунок 3 – Преобразование столбца «Угол нашивки, град»

Таким образом, были описаны задачи данной работы и даны характеристики датасета. На следующем этапе работы (подраздел 1.2) будут рассмотрены методы машинного обучения, применяемые для решения сформулированной регрессионной задачи, с обоснованием их выбора на основе характера данных и поставленных целей.

В рамках разведочного анализа данных (подраздел 1.3) планируется провести визуализацию распределения переменных с использованием гистограмм и диаграмм ящика с усами, оценить статистические характеристики (среднее, медиана), выявить и обработать выбросы, а также проанализировать взаимосвязи между признаками с помощью попарных графиков рассеяния и матрицы корреляции.

1.2 Описание используемых методов

По классификации задач машинного обучения данная задача относится к обучению с учителем (supervised learning) и представляет собой регрессионную задачу, поскольку выходные переменные являются непрерывными числовыми величинами. Для решения поставленной задачи были применены следующие методы:

- 1) множественная линейная регрессия;
- 2) случайный лес;
- 3) градиентный бустинг (XGBoost);
- 4) метод опорных векторов (SVR);
- 5) К-ближайших соседей.

Множественная линейная регрессия (Multiple Linear Regression) моделирует линейную зависимость между несколькими независимыми переменными (признаками) и одной непрерывной целевой переменной. Обучение заключается в подборе коэффициентов, минимизирующих среднеквадратичную ошибку методом наименьших квадратов.

Достоинства: простота интерпретации, высокая скорость, не требует настройки гиперпараметров.

Недостатки: не учитывает нелинейности, чувствительна к выбросам и мультиколлинеарности.

Случайный лес (Random Forest) - ансамблевый метод, строящий множество решающих деревьев на случайных подвыборках данных и признаков. Итоговый прогноз получается усреднением предсказаний всех деревьев.

Достоинства: высокая точность, устойчивость к выбросам, не требует нормализации, оценка важности признаков.

Недостатки: сложность интерпретации, высокое потребление памяти.

Градиентный бустинг (Gradient Boosting) - ансамблевый метод, строящий деревья последовательно, где каждое следующее дерево исправляет ошибки предыдущего. В работе используется реализация XGBoost (eXtreme Gradient

Boosting). XGBoost минимизирует регуляризованную функцию потерь, что позволяет эффективно бороться с переобучением

Достоинства: высокая точность, регуляризация, скорость, оценка важности признаков.

Недостатки: сложность настройки гиперпараметров, чувствительность к выбросам.

Метод опорных векторов для регрессии (SVR, Support Vector Regression) строит функцию, отклоняющуюся от фактических значений не более чем на заданную величину ϵ . Допускает использование ядер для учёта нелинейных зависимостей.

Достоинства: эффективен в пространствах высокой размерности, работает на малых выборках, устойчив к выбросам.

Недостатки: плохо масштабируется на большие данные, требует нормализации признаков, сложность настройки гиперпараметров.

Метод К-ближайших соседей (KNN, K-Nearest Neighbors) - это непараметрический алгоритм, который для прогнозирования числового значения находит К ближайших к объекту точек в обучающей выборке и вычисляет среднее арифметическое значений их целевых переменных

Достоинства: отсутствие этапа обучения, универсальность (подходит для классификации и регрессии), интерпретируемость результатов, адаптивность через выбор метрики и весов соседей.

Недостатки: низкая производительность при большом объёме данных; сложности при подборе гиперпараметров; чувствителен к выбросам.

Выбранные методы охватывают различные подходы к регрессии: линейный (множественная линейная регрессия), ансамблевый (случайный лес, XGBoost), ядерный (SVR) и непараметрический (KNN), что позволяет провести сравнительный анализ и выбрать оптимальную модель для прогнозирования механических свойств композиционных материалов.

1.3 Разведочный анализ данных

Цель разведочного анализа данных - предварительное исследование набора данных с целью определения его основных характеристик, взаимосвязей между признаками, а также для выбора набора методов, которые будут использоваться в дальнейшем для создания моделей машинного обучения.

В подразделе 1.1 была начата работа с датасетом: он был объединён из двух, были проделаны проверки на пропуски, дубликаты и уникальные значения.

В этом подразделе хотелось бы сосредоточиться больше на описательной статистике и визуализации.

На рисунке 4 представлены описательные статистики для всех числовых признаков: среднее, медиана, стандартное отклонение, минимальное и максимальное значения, а также квартили. Среднее значение модуля упругости при растяжении составило 73,33 ГПа при стандартном отклонении 3,12 ГПа, прочности при растяжении — 2466,92 МПа при стандартном отклонении 485,63 МПа. Разброс значений прочности существенно выше, чем у модуля упругости, что указывает на большую чувствительность прочности к изменению входных параметров. Минимальное значение прочности (1036,86 МПа) почти в 4 раза ниже среднего, что подтверждает наличие выбросов в данных. Признак «Угол нашивки, град» является бинарным, что подтверждается медианой, равной 0, и 75-м перцентилем, равным 1.

```
]: df.describe()
```

	Соотношение матрица-наполнитель	Плотность, кг/м3	модуль упругости, ГПа	Количество отвердителя, м.%	Содержание эпоксидных групп, %_2	Температура вспышки, C_2	Поверхностная плотность, г/м2	Модуль упругости при растяжении, ГПа	Прочность при растяжении, МПа	Потребление смолы, г/м2	Угол нашивки, град	Шаг нашивки	Плотность нашивки
count	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000	1023.000000
mean	2.930366	1975.734888	739.923233	110.570769	22.244390	285.882151	482.731833	73.328571	2466.922843	218.423144	0.491691	6.899222	57.153929
std	0.913222	73.729231	330.231581	28.295911	2.406301	40.943260	281.314690	3.118983	485.628006	59.735931	0.500175	2.563467	12.350969
min	0.389403	1731.764635	2.436909	17.740275	14.254985	100.000000	0.603740	64.054061	1036.856605	33.803026	0.000000	0.000000	0.000000
25%	2.317887	1924.155467	500.047452	92.443497	20.608034	259.066528	266.816645	71.245018	2135.850448	179.627520	0.000000	5.080033	49.799212
50%	2.906878	1977.621657	739.664328	110.564840	22.230744	285.896812	451.864365	73.268805	2459.524526	219.198882	0.000000	6.916144	57.341920
75%	3.552660	2021.374375	961.812526	129.730366	23.961934	313.002106	693.225017	75.356612	2767.193119	257.481724	1.000000	8.586293	64.944961
max	5.591742	2207.773481	1911.536477	198.953207	33.000000	413.273418	1399.542362	82.682051	3848.436732	414.590628	1.000000	14.440522	103.988901

Рисунок 4 – Описательная статистика

В соответствии с рисунком 5, для визуальной оценки распределения каждой переменной построены гистограммы. Результаты теста Шапиро-Уилка показали, что распределение большинства признаков (9 из 13) не противоречит нормальному распределению на уровне значимости 0,05, в то время как для признаков «модуль упругости, ГПа», «поверхностная плотность, г/м²», «угол нашивки, град» и «плотность нашивки» гипотеза о нормальности была отвергнута.

Биквадратный признак «Угол нашивки, град» имеет два чётко выраженных пика (0 и 1), что подтверждает его бинарную природу после выполненного преобразования.




Рисунок 5 – Гистограммы распределения

Для выявления выбросов построены диаграммы ящика с усами, которые показали наличие аномальных значений во всех, кроме «Угол нашивки, град», в соответствии с рисунком 6.




Рисунок 6 – Диаграммы «ящика с усами»

Для оценки попарных взаимосвязей между переменными построены графики рассеяния точек, которые показали отсутствие ярко выраженных линейных зависимостей - взаимосвязи между признаками и целевыми переменными носят скорее нелинейный характер.




Рисунок 7 – Попарные графики рассеяния точек

В соответствии с рисунком 8 анализ тепловой карты корреляционной матрицы показывает, что коэффициенты корреляции между входными признаками и целевыми переменными близки к нулю. Это свидетельствует об отсутствии сильных линейных зависимостей в данных и подтверждает необходимость использования нелинейных методов машинного обучения для решения поставленной задачи.




Рисунок 8 – Тепловая карта матрицы корреляции

Выявленные выбросы будут обработаны на этапе предобработки данных с использованием IQR-метода. Таким образом, результаты разведочного анализа подтверждают необходимость масштабирования признаков для моделей, чувствительных к этому, и обосновывают выбор методов машинного обучения для решения поставленной регрессионной задачи.

Практическая часть

2.1 Предобработка данных

Разведочный анализ был выполнен, теперь можно переходить к очистке данных и исправлению обнаруженных ранее проблем.

Метод IQR основан на межквартильном размахе и не требует нормальности распределения. Поскольку не все признаки в датасете имеют нормальное распределение, что подтверждено тестом Шапиро–Уилка, предпочтение было отдано IQR-методу.

Вышеупомянутый метод был применён дважды, так как после первого остались незначительные выбросы. В соответствии с рисунком 9 данные без выбросов.




Рисунок 9 – Диаграммы «ящик с усами» после удаления выбросов

Поскольку признаки имеют различные диапазоны значений (например, плотность измеряется в кг/м^3 и варьируется от 1700 до 2200, а модуль упругости связующего — от 2 до 1900 ГПа), для моделей, чувствительных к масштабу

признаков (линейная регрессия, SVR, нейронная сеть), необходимо привести данные к единому масштабу. Это позволит избежать ситуации, когда признаки с большими числовыми значениями доминируют над признаками с меньшими значениями. Для ансамблевых моделей (случайный лес, XGBoost) нормализация не требуется, однако её проведение не ухудшает их работу, так как деревья решений не чувствительны к масштабу признаков. В данной работе для нормализации выбран метод MinMaxScaler, который приводит значения признаков к диапазону $[0, 1]$. Для приведения признаков к единому масштабу был выбран именно этот метод, так как распределения части признаков отличаются от нормального. Стандартизация не применялась, поскольку использование двух методов масштабирования последовательно нецелесообразно и может исказить данные. Бинарный признак «Угол нашивки, град» и выходные переменные не были нормализованы (рис. 10).

до нормализации (MinMaxScaler):

[32]:	Соотношение матрица-наполнитель	Плотность, кг/м3	модуль упругости, ГПа	Количество отвердителя, м.%	Содержание эпоксидных групп, %_2	Температура вспышки, C_2	Поверхностная плотность, г/м2	Потребление смолы, г/м2	Шаг нашивки	Плотность нашивки
1	1.857143	2030.0	738.736842	50.00	23.750000	284.615385	210.0	220.0	4.0	60.0
3	1.857143	2030.0	738.736842	129.00	21.250000	300.000000	210.0	220.0	5.0	47.0
4	2.771331	2030.0	753.000000	111.86	22.267857	284.615385	210.0	220.0	5.0	57.0
5	2.767918	2000.0	748.000000	111.86	22.267857	284.615385	210.0	220.0	5.0	60.0
6	2.569620	1910.0	807.000000	111.86	22.267857	284.615385	210.0	220.0	5.0	70.0


```
[30]: #данные после нормализации
print("после нормализации (MinMaxScaler):")
df_scaled[cols_to_scale].head()
```

после нормализации (MinMaxScaler):

[30]:	Соотношение матрица-наполнитель	Плотность, кг/м3	модуль упругости, ГПа	Количество отвердителя, м.%	Содержание эпоксидных групп, %_2	Температура вспышки, C_2	Поверхностная плотность, г/м2	Потребление смолы, г/м2	Шаг нашивки	Плотность нашивки
1	0.274768	0.651097	0.452951	0.079153	0.607435	0.509164	0.16223	0.514688	0.289334	0.546433
3	0.274768	0.651097	0.452951	0.630983	0.418887	0.583596	0.16223	0.514688	0.362355	0.319758
4	0.466552	0.651097	0.461725	0.511257	0.495653	0.509164	0.16223	0.514688	0.362355	0.494123
5	0.465836	0.571539	0.458649	0.511257	0.495653	0.509164	0.16223	0.514688	0.362355	0.546433
6	0.424236	0.332865	0.494944	0.511257	0.495653	0.509164	0.16223	0.514688	0.362355	0.720799

Рисунок 10 – Данные до и после нормализации

Для проверки корректности нормализации были проанализированы минимальные и максимальные значения признаков после применения MinMaxScaler. Как показано на рисунке 11, все нормализованные признаки имеют минимальное значение 0.0 и максимальное значение 1.0, что подтверждает успешное

приведение данных к единому диапазону [0, 1]. Таким образом, данные подготовлены для дальнейшего обучения моделей машинного обучения.

```
# Проверяем min и max для всех нормализованных признаков
print("Минимальные значения после нормализации:")
print(df_scaled[cols_to_scale].min())
print("\nМаксимальные значения после нормализации:")
print(df_scaled[cols_to_scale].max())
```

Минимальные значения после нормализации:

Соотношение матрица-наполнитель	0.0
Плотность, кг/м3	0.0
модуль упругости, ГПа	0.0
Количество отвердителя, м.%	0.0
Содержание эпоксидных групп,%_2	0.0
Температура вспышки, C_2	0.0
Поверхностная плотность, г/м2	0.0
Потребление смолы, г/м2	0.0
Шаг нашивки	0.0
Плотность нашивки	0.0

dtype: float64

Максимальные значения после нормализации:

Соотношение матрица-наполнитель	1.0
Плотность, кг/м3	1.0
модуль упругости, ГПа	1.0
Количество отвердителя, м.%	1.0
Содержание эпоксидных групп,%_2	1.0
Температура вспышки, C_2	1.0
Поверхностная плотность, г/м2	1.0
Потребление смолы, г/м2	1.0
Шаг нашивки	1.0
Плотность нашивки	1.0

dtype: float64

Рисунок 11 – Максимальные и минимальные значения после нормализации

После удаления выбросов объём выборки составил 921 запись. Данные были разделены на обучающую (70%) и тестовую (30%) выборки. Обучающая выборка содержит 644 записи, тестовая — 277 записей.

Для оценки качества моделей будут использоваться следующие метрики: средняя абсолютная ошибка (MAE) - для интерпретируемой оценки ошибки в единицах целевой переменной, среднеквадратическая ошибка (RMSE) - для оценки стандартного отклонения ошибок, и коэффициент детерминации R^2 - для оценки доли объяснённой дисперсии. MAE и RMSE будут рассчитаны в тех

же единицах, что и целевые переменные (ГПа и МПа), что позволит содержательно интерпретировать точность моделей.

2.2 Разработка и обучение модели

Для прогнозирования целевых переменных (модуля упругости при растяжении и прочности при растяжении) были выбраны пять моделей машинного обучения: множественная линейная регрессия, случайный лес, градиентный бустинг (XGBoost), метод опорных векторов (SVR) и метод К-ближайших соседей (KNN). Выбор данных методов обусловлен результатами разведочного анализа, которые показали наличие нелинейных зависимостей между признаками и целевыми переменными, а также необходимостью сравнить различные подходы к решению регрессионной задачи.

На первом этапе данные были разделены на матрицу признаков X и вектор целевых переменных. В качестве целевых переменных использованы «Модуль упругости при растяжении, ГПа» и «Прочность при растяжении, МПа». Матрица признаков содержит 11 переменных, описывающих параметры компонентов и технологического процесса. Объём выборки после удаления выбросов составил 921 наблюдение.

Для оценки качества моделей данные были разделены на обучающую (70%) и тестовую (30%) выборки с использованием функции `train_test_split` и фиксированным параметром `random_state=42` для обеспечения воспроизводимости результатов. Размер обучающей выборки составил 644 наблюдения, тестовой - 277 наблюдений. Для обеих целевых переменных использовалось одинаковое разбиение, что обеспечивает сопоставимость результатов.

В соответствии с заданием при построении моделей был проведён поиск гиперпараметров с использованием `GridSearchCV` с 10-кратной перекрёстной проверкой (`cv=10`). В качестве метрики для выбора лучшей конфигурации использовался коэффициент детерминации R^2 (`scoring='r2'`). Для каждой модели была задана индивидуальная сетка гиперпараметров, включающая основные

настройки: число деревьев и их максимальную глубину для ансамблевых методов, скорость обучения для XGBoost, параметр регуляризации и ширину ε-трубки для SVR, число соседей и метрику расстояния для KNN.

По результатам поиска для каждой модели были определены лучшие гиперпараметры. GridSearchCV возвращает готовую модель (`best_estimator_`), уже обученную с лучшими гиперпараметрами на полной обучающей выборке. Данная модель использовалась для предсказания на тестовой выборке. Оценка качества моделей производилась с использованием метрик MAE, RMSE и R^2 , результаты которой представлены в разделе 2.3.

Аналогичным образом были обучены модели для прогнозирования прочности при растяжении. Использованы те же пять моделей с теми же сетками гиперпараметров и той же 10-кратной кросс-валидацией.

Важно отметить, что для модуля упругости и прочности при растяжении оптимальные гиперпараметры могут отличаться. Это объясняется тем, что данные целевые переменные являются разными физическими величинами с разными диапазонами значений и разной степенью зависимости от входных признаков. Поэтому поиск гиперпараметров для каждой целевой переменной выполнялся независимо, что позволяет подобрать наиболее подходящую конфигурацию модели для каждой задачи. Результаты поиска гиперпараметров для обеих целевых переменных представлены на рисунках 12 и 13.

ГИПЕРПАРАМЕТРЫ ДЛЯ МОДУЛЯ УПРУГОСТИ ПРИ РАСТЯЖЕНИИ

```
Random Forest: {'max_depth': 5, 'min_samples_split': 5, 'n_estimators': 100}
XGBoost:       {'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 50}
SVR:           {'C': 0.1, 'epsilon': 0.1, 'kernel': 'rbf'}
KNN:           {'metric': 'euclidean', 'n_neighbors': 11, 'weights': 'uniform'}
```

Рисунок 12 – Гиперпараметры для модуля упругости при растяжении

ГИПЕРПАРАМЕТРЫ ДЛЯ ПРОЧНОСТИ ПРИ РАСТЯЖЕНИИ

```
Random Forest: {'max_depth': 5, 'min_samples_split': 10, 'n_estimators': 200}
XGBoost:      {'learning_rate': 0.01, 'max_depth': 7, 'n_estimators': 50}
SVR:          {'C': 0.1, 'epsilon': 0.01, 'kernel': 'rbf'}
KNN:          {'metric': 'manhattan', 'n_neighbors': 11, 'weights': 'distance'}
```

Рисунок 13 – Гиперпараметры для прочности при растяжении

2.3 Тестирование модели

Оценка точности моделей проводилась на тестовой выборке (30% данных, 277 наблюдений) с использованием трёх метрик: средней абсолютной ошибки (MAE), корня из среднеквадратичной ошибки (RMSE) и коэффициента детерминации R^2 .

Результаты обучения моделей для прогнозирования модуля упругости при растяжении представлены на рисунке 14.

Model	MAE	RMSE	R2
Linear Regression	2.455	3.013	-0.0001
Random Forest	2.457	3.026	-0.0088
XGBoost	2.465	3.019	-0.0042
SVR	2.445	3.005	0.0049
KNN	2.566	3.140	-0.0862

Рисунок 14 – Результаты обучения моделей по прогнозированию модуля упругости при растяжении

Как видно из таблицы 14, значения коэффициента детерминации R^2 для всех моделей близки к нулю или отрицательны. Наилучший результат показала модель SVR ($R^2 = 0.0049$), наихудший - модель KNN ($R^2 = -0.0862$). Отрицательные значения R^2 означают, что модели предсказывают целевую переменную хуже, чем простая модель, всегда выдающая среднее значение. MAE для всех

моделей находится в диапазоне от 2.445 до 2.566 ГПа, RMSE - от 3.005 до 3.140 ГПа.

Результаты обучения моделей для прогнозирования прочности при растяжении представлены в таблице 15.

Model	MAE	RMSE	R2
Linear Regression	384.030	474.086	0.0012
Random Forest	384.623	475.115	-0.0031
XGBoost	383.043	475.344	-0.0041
SVR	383.595	474.458	-0.0003
KNN	401.683	497.752	-0.1010

Рисунок 15 – Результаты обучения моделей по прогнозированию прочности при растяжении

Как видно из таблицы 15, результаты для прочности при растяжении аналогичны результатам для модуля упругости. Наилучший результат показала модель линейной регрессии ($R^2 = 0.0012$), наихудший - модель KNN ($R^2 = -0.1009$). MAE для всех моделей находится в диапазоне от 383.043 до 401.683 МПа, RMSE - от 474.086 до 497.752 МПа.

Наилучший результат для прочности при растяжении показала линейная регрессия ($R^2 = 0.0012$). Однако это не означает, что линейная модель действительно хорошо описывает данные — значение R^2 крайне близко к нулю и находится в пределах статистической погрешности. Сложные ансамблевые модели (случайный лес, XGBoost) показали отрицательные значения R^2 , что объясняется их склонностью к переобучению на шумовых данных при отсутствии реальных зависимостей. Таким образом, результат линейной регрессии следует интерпретировать не как её преимущество, а как следствие отсутствия информативных признаков в данных.

Учитывая близкие к нулевым и отрицательные значения коэффициента детерминации, прямое сравнение моделей по метрикам MAE и RMSE не имеет смысла. Результаты работы всех моделей для обеих целевых переменных следует признать неудовлетворительными: ни одна из моделей не смогла объяснить дисперсию целевых переменных лучше, чем простая модель, предсказывающая среднее значение.

Полученный результат согласуется с выводами разведочного анализа данных. Это указывает на то, что прогнозирование механических свойств композиционных материалов на основе имеющегося набора признаков является сложной задачей.

2.4 Нейронная сеть

В отличие от задач 1 и 2 (прогнозирование модуля упругости и прочности), задача 3 является обратной: по заданным характеристикам компонентов и желаемым конечным свойствам композита требуется рекомендовать оптимальное соотношение матрица-наполнитель. Для решения этой задачи разработана полносвязная нейронная сеть.

Входными признаками нейронной сети являются 12 переменных – все столбцы объединённого датасета, кроме целевой переменной «Соотношение матрица-наполнитель». Целевой переменной является само соотношение матрица-наполнитель. Разделение данных выполнено с использованием функции `train_test_split` (обучающая выборка – 70% (644 наблюдения), тестовая выборка – 30% (277 наблюдений)) с параметром `random_state=42` для воспроизводимости результатов.

Для решения задачи использована полносвязная нейронная сеть на основе класса `Sequential` библиотеки `tensorflow.keras`. Архитектура сети, изображенная на рисунке 16, включает входной слой, два скрытых слоя, два слоя регуляризации и выходной слой. Входной слой принимает двенадцать признаков. Первый скрытый слой содержит 64 нейрона с активацией ReLU, второй скрытый слой –

32 нейрона также с активацией ReLU. После каждого скрытого слоя добавлен слой Dropout с коэффициентом 0.2, отключающий 20% нейронов на каждой итерации обучения для борьбы с переобучением. Выходной слой содержит один нейрон с линейной активацией, что соответствует задаче регрессии. Общее число обучаемых параметров сети составляет 2 945.

Model: "sequential_2"

Layer (type)	Output Shape	Param #
dense_6 (Dense)	(None, 64)	832
dropout_4 (Dropout)	(None, 64)	0
dense_7 (Dense)	(None, 32)	2,080
dropout_5 (Dropout)	(None, 32)	0
dense_8 (Dense)	(None, 1)	33

Total params: 2,945 (11.50 KB)

Trainable params: 2,945 (11.50 KB)

Non-trainable params: 0 (0.00 B)

Рисунок 16 – Архитектура нейронной сети для соотношения матрица-наполнитель

Выбор архитектуры обусловлен характером задачи и объёмом данных. Поскольку задача является регрессионной, а количество наблюдений ограничено 921 записью, использование более глубоких сетей привело бы к переобучению. Два скрытых слоя обеспечивают достаточную выразительную способность для моделирования нелинейных зависимостей между признаками и целевой переменной при умеренном числе параметров. Первый скрытый слой

расширяет пространство признаков, позволяя сети улавливать сложные нелинейные взаимосвязи, второй – постепенно сжимает информацию, выделяя наиболее значимые признаки. Активация ReLU выбрана для скрытых слоёв как стандартная функция, обеспечивающая нелинейность и устойчивость градиентов при обучении. Слои Dropout добавлены для повышения устойчивости модели и снижения риска переобучения. Линейная активация на выходном слое позволяет предсказывать непрерывное числовое значение без ограничений диапазона.

Модель скомпилирована с оптимизатором Adam и скоростью обучения 0.001. Оптимизатор Adam является адаптивным методом, автоматически подбирающим индивидуальный шаг обучения для каждого веса, и хорошо зарекомендовал себя при работе с табличными данными. В качестве функции потерь и метрики выбрана средняя абсолютная ошибка (MAE), которая интерпретируется в единицах целевой переменной и устойчива к выбросам.

Обучение проводилось с использованием метода fit. Из обучающей выборки 20% (около 129 наблюдений) было выделено для валидации – контроля переобучения в процессе обучения. Обучение весов производилось на оставшихся 80% обучающей выборки (около 515 наблюдений). Количество эпох обучения составило 200, размер батча – 32. Тестовая выборка (277 наблюдений) не участвовала в обучении и использовалась только для финальной оценки качества модели.

В процессе обучения наблюдалось устойчивое снижение ошибки. На первой эпохе значение функции потерь на обучающей выборке составило 218.36, на валидационной – 105.19. К двухсотой эпохе ошибка на обучении снизилась до 0.19, на валидации – до 0.16. Близкие значения функции потерь на обучающей и валидационной выборках в конце обучения свидетельствуют об отсутствии переобучения. Разница между ними составляет всего 0.03, что подтверждает способность модели обобщать данные. Более детальный анализ кривых обучения и распределения ошибок представлен ниже на рисунке 17.




Рисунок 17 – Значения функции потерь на первой и последней эпохах

Оценка обученной модели на тестовой выборке (277 наблюдений) показала следующие результаты: $MAE = 0.1507$, $RMSE = 0.1868$, $R^2 = -0.0117$ (рисунок 18).

РЕЗУЛЬТАТЫ НЕЙРОННОЙ СЕТИ (соотношение матрица-наполнитель)

MAE: 0.1507

RMSE: 0.1868

R^2 : -0.0117

Рисунок 18 – Результаты нейронной сети

Для проверки качества модели было выполнено сравнение с базовой моделью, предсказывающей для любого объекта среднее значение целевой переменной из обучающей выборки. Baseline MAE составила 0.1496, что немного меньше MAE нейронной сети (0.1507). Таким образом, модель не извлекает полезной информации из признаков лучше, чем простое предсказание среднего.

Отрицательное значение коэффициента детерминации R^2 подтверждает этот вывод: модель объясняет дисперсию целевой переменной хуже, чем базовая модель. Стандартное отклонение целевой переменной на тестовой выборке составляет 0.1861, что сопоставимо с MAE модели (0.1507). Это означает, что ошибка модели почти равна разбросу значений целевой переменной.

Полученный результат согласуется с выводами разведочного анализа данных: матрица корреляции показала слабую линейную связь между соотношением матрица-наполнитель и остальными признаками (коэффициенты корреляции близки к нулю). Это ограничивает возможность прогнозирования данной целевой переменной на основе имеющегося набора признаков.

2.5 Разработка приложения

Для практического использования разработанной нейронной сети создано веб-приложение на основе фреймворка FastAPI. Разработка выполнялась в среде Visual Studio Code (VS Code). Приложение реализует REST API, которое принимает на вход 12 параметров композита и возвращает рекомендованное соотношение матрица-наполнитель.

Структура создания веб-приложения включает в себя следующие файлы, продемонстрированные в таблице 1.

Таблица 1 – файлы, использованные для создания веб-приложения

Файл	Назначение
main.py	Код FastAPI-приложения
nn_matrix_filler.keras	Обученная нейронная сеть
scaler_minmax.pkl	Сохранённый нормализатор MinMaxScaler
feature_order.pkl	Порядок входных признаков
requirements.txt	Список зависимостей Python

Для тестирования API используется встроенный интерфейс Swagger UI, доступный по адресу <http://localhost:8000/docs>. В соответствии с рисунком 19, тестирование прошло успешно – код 200.

Server response	
Code	Details
200	Response body <pre>{ "matrix_filler_ratio": 0.48569855093955994 }</pre>

Рисунок 19 – Результат тестирования API

Приложение работает следующим образом: пользователь вводит 12 параметров композита через веб-интерфейс, приложение нормализует их с помощью сохранённого MinMaxScaler, подаёт в нейронную сеть и возвращает прогноз.

localhost:8000/app

Прогноз соотношения матрица-наполнитель

Плотность, кг/м³:

Модуль упругости связующего, ГПа:

Количество отвердителя, м.-%:

Содержание эпоксидных групп, %:

Температура всплышки, °C:

Поверхностная плотность, г/м²:

Модуль упругости при растяжении, ГПа:

Прочность при растяжении, МПа:

Потребление смолы, г/м²:

Угол нашивки, град:

Шаг нашивки:

Плотность нашивки:

Рассчитать

Рекомендованное соотношение:
0.4857

Рисунок 20 – Веб-интерфейс приложения для прогнозирования соотношения матрица-наполнитель

Инструкция по установке и запуску приложения:

- 1) Скачайте все файлы для веб-приложения из репозитория (app) на свой компьютер и поместите их в одну папку. В папке должны находиться следующие файлы: `main.py`, `nn_matrix_filler.keras`, `scaler_minmax.pkl`, `feature_order.pkl`, `requirements.txt`;
- 2) Установите Python версии 3.9 или выше, если он ещё не установлен;
- 3) Откройте терминал и перейдите в папку с файлами приложения;
- 4) Установите необходимые зависимости, выполнив команду: `pip install -r requirements.txt`. Установка может занять несколько минут, так как загружается библиотека TensorFlow;
- 5) Убедитесь, что терминал находится в папке и запустите сервер командой: `python -m uvicorn main:app --reload`.
- 6) Дождитесь появления сообщения `Application startup complete`. Это означает, что сервер запущен и приложение готово к работе.
- 7) Откройте браузер и перейдите по адресу <http://localhost:8000/app> - откроется веб-интерфейс приложения с полями для ввода параметров композита.

В ходе тестирования приложения было установлено, что нейронная сеть возвращает одинаковый прогноз (0.4857) независимо от входных параметров. При подаче нормальных значений (плотность 1975 кг/м³, прочность 2466 МПа), заведомо заниженных значений (все параметры равны 5) и завышенных значений (все параметры равны 100) модель выдаёт одно и то же значение. Это означает, что модель фактически «схлопнулась» в константу, предсказывая среднее значение целевой переменной.

Такое поведение согласуется с результатами оценки качества модели:

- 1) $R^2 = -0.0117$ — модель объясняет дисперсию целевой переменной хуже, чем базовая модель, предсказывающая среднее;
- 2) MAE модели = 0.1507 против MAE базовой модели = 0.1496 — модель не лучше простого предсказания среднего.

Причиной является слабая связь между входными признаками и целевой переменной «Соотношение матрица-наполнитель». Корреляционный анализ (раздел 1.3) показал, что коэффициенты корреляции между признаками и целевой переменной близки к нулю. Кроме того, стандартное отклонение целевой переменной на тестовой выборке (0.1861) сопоставимо с MAE модели (0.1507), что подтверждает отсутствие информативного сигнала в данных.

Необходимо подчеркнуть, что низкое качество прогноза обусловлено исходным датасетом, а не ошибками реализации. Разработанное приложение корректно принимает, нормализует и обрабатывает входные данные, а также интегрирует нейронную сеть. Для повышения качества прогноза может потребоваться расширение набора входных данных или применение физически обоснованных моделей, учитывающих механику композиционных материалов.

2.6. Удалённый репозиторий

Все материалы исследовательской работы размещены в публичном репозитории на GitHub. Репозиторий доступен по ссылке: <https://github.com/melnichenko-ds/Composite-Materials>

Заключение

В рамках данной выпускной квалификационной работы была достигнута поставленная цель – разработаны модели машинного обучения для прогнозирования свойств композиционных материалов, а также создано нейросетевое решение для рекомендации соотношения матрица-наполнитель и веб-приложение для практического использования разработанных моделей.

В ходе выполнения работы были решены следующие задачи.

- 1) Проведён разведочный анализ предоставленных данных;
- 2) Выполнена предобработка данных;
- 3) Для прогнозирования модуля упругости при растяжении и прочности при растяжении обучены пять моделей машинного обучения;
- 4) Разработана нейронная сеть для рекомендации соотношения матрица-наполнитель;
- 5) Создано веб-приложение на основе фреймворка FastAPI для приёма 12 параметров композита и возврата рекомендованного соотношения матрица-наполнитель.

Прогнозирование свойств композиционных материалов на основе имеющегося набора признаков является сложной задачей. Низкое качество моделей обусловлено слабой корреляцией между входными параметрами и целевыми переменными, что подтверждено результатами разведочного анализа и оценки моделей.

Нейронная сеть для рекомендации соотношения матрица-наполнитель также не показала удовлетворительного качества, «схлопнувшись» в константу, предсказывающую среднее значение целевой переменной.

Несмотря на низкое качество прогнозов, работа представляет методическую ценность: продемонстрирован полный цикл анализа данных – от разведочного анализа и предобработки до обучения моделей, разработки нейронной сети,

создания веб-приложения и размещения кода в репозитории. Выявлены ограничения исходного датасета для решения поставленных задач.

Практическая значимость работы заключается в создании работающего приложения, которое может быть использовано как основа для дальнейших исследований. Для повышения качества прогноза рекомендуется расширение набора входных данных (например, добавление информации о микроструктуре, химическом составе компонентов, условиях испытаний) или применение физически обоснованных моделей, учитывающих механику композиционных материалов.

Таким образом, все задачи, поставленные в выпускной квалификационной работе, выполнены в полном объеме. Полученные результаты могут служить базой для дальнейших исследований в области материаловедения.

Библиографический список

Книги и учебные пособия

1. Андерсон, К. Аналитическая культура. От сбора данных до бизнес-результатов [Текст] / К. Андерсон ; пер. с англ. Ю. Константиновой. – М. : Манн, Иванов и Фербер, 2017. – 336 с.
2. Бринк, Х. Машинное обучение [Текст] / Х. Бринк, Дж. Ричардс, М. Февеолф. – СПб. : Питер, 2017. – 336 с.
3. Брюс, П. Практическая статистика для специалистов Data Science [Текст] / П. Брюс, Э. Брюс, П. Гедек ; пер. с англ. – 2-е изд., перераб. и доп. – СПб. : БХВ-Петербург, 2021. – 368 с.
4. Васильев, Ю. Python для data science [Текст] / Ю. Васильев. – СПб. : Питер, 2025. – 272 с.
5. Грас, Д. Data Science. Наука о данных с нуля [Текст] / Д. Грас ; пер. с англ. – 2-е изд., перераб. и доп. – СПб. : БХВ-Петербург, 2025. – 416 с.
6. Джулли, П. Библиотека Keras — инструмент глубокого обучения [Текст] / П. Джулли ; пер. с англ. А. А. Слинкина. – М. : ДМК Пресс, 2017. – 249 с.
7. Жерон, О. Прикладное машинное обучение с помощью Scikit-Learn и TensorFlow: концепции, инструменты и техники для создания интеллектуальных систем [Текст] / О. Жерон ; пер. с англ. – СПб. : Альфа-книга, 2018. – 688 с.
8. Любанович, Б. Простой Python. Современный стиль программирования [Текст] / Б. Любанович. – СПб. : Питер, 2016. – 480 с.
9. Маккини, У. Python и анализ данных: Первичная обработка данных с применением pandas, NumPy и Jupyter [Текст] / У. Маккини ; пер. с англ. А. А. Слинкина. – 3-е изд. – М. : ДМК Пресс, 2023. – 536 с.
10. Мюллер, А. Введение в машинное обучение с помощью Python [Текст] / А. Мюллер, С. Гвидо. – М. : Диалектика, 2017. – 480 с.

11. Николенко, С. И. Глубокое обучение. Погружение в мир нейронных сетей [Текст] / С. И. Николенко, А. Кадури, Е. Архангельская. – СПб. : Питер, 2018. – 480 с.
12. Нисчал, Н. Python — это просто. Пошаговое руководство по программированию и анализу данных [Текст] / Н. Нисчал ; пер. с англ. – СПб. : БХВ-Петербург, 2022. – 416 с.
13. Роббинс, Дж. HTML5: карманный справочник [Текст] / Дж. Роббинс ; пер. с англ. – 5-е изд. – М. : Вильямс, 2015. – 192 с.
14. Силен, Д. Основы Data Science и Big Data. Python и наука о данных [Текст] / Д. Силен, А. Мейсман, М. Али. – СПб. : Питер, 2017. – 336 с.
15. Тарасенко, Ф. П. Прикладной системный анализ [Текст] : учебное пособие / Ф. П. Тарасенко. – М. : КНОРУС, 2010. – 224 с.
16. Траск, Э. Грожаем глубокое обучение [Текст] / Э. Траск. – СПб. : Питер, 2019. – 352 с.
17. Флах, П. Машинное обучение. Наука и искусство построения алгоритмов [Текст] / П. Флах. – М. : ДМК Пресс, 2015. – 400 с.
18. Чен, Т. XGBoost: масштабируемая система повышения градиента [Текст] / Т. Чен, К. Гестрин // Материалы 22-й международной конференции ACM SIGKDD. – 2016. – с. 785–794.
19. Шитиков, В. К. Классификация, регрессия и другие алгоритмы Data Mining с использованием R [Электронный ресурс] / В. К. Шитиков, С. Э. Мостицкий. – 2017. – 351 с. – Режим доступа: <https://github.com/ranalytics/data-mining>. (дата обращения: 28.08.2026).
20. Kushvaha, V. Machine Learning Applied to Composite Materials [Text] / V. Kushvaha, A. K. Sharma, P. K. Rakesh. – Singapore : Springer, 2025. – 300 p.
21. Mishra, A. Sustainable Materials: The Role of Artificial Intelligence and Machine Learning [Text] / A. Mishra, V. S. Jatti, S. Paliwal. – Boca Raton : CRC Press, 2024. – 320 p.

22. Rogel-Salazar, J. Data Science and Analytics with Python [Text] / J. Rogel-Salazar. – 2nd ed. – Boca Raton : CRC Press, 2025. – 514 p.

Интернет-ресурсы

23. Документация по библиотеке Matplotlib [Электронный ресурс]. – Режим доступа: <https://matplotlib.org/stable/users/index.html>. (дата обращения: 18.08.2026).

24. Документация по библиотеке NumPy [Электронный ресурс]. – Режим доступа: <https://numpy.org/doc/stable/>. (дата обращения: 15.08.2026).

25. Документация по библиотеке pandas [Электронный ресурс]. – Режим доступа: <https://pandas.pydata.org/docs/>. (дата обращения: 15.08.2026).

26. Документация по библиотеке scikit-learn [Электронный ресурс]. – Режим доступа: https://scikit-learn.org/stable/user_guide.html. (дата обращения: 02.09.2026).

27. Документация по библиотеке Seaborn [Электронный ресурс]. – Режим доступа: <https://seaborn.pydata.org/tutorial.html>. (дата обращения: 18.08.2026).

28. Документация по библиотеке TensorFlow [Электронный ресурс]. – Режим доступа: https://www.tensorflow.org/api_docs. (дата обращения: 11.09.2026).

29. Документация по фреймворку FastAPI [Электронный ресурс]. – Режим доступа: <https://fastapi.tiangolo.com/>. (дата обращения: 24.09.2026).

30. Документация по языку программирования Python [Электронный ресурс]. – Режим доступа: <https://docs.python.org/3/>. (дата обращения: 15.08.2026).